Bài tập lớn: Nền tảng lập trình cho phân tích và trực quan dữ liệu

Trường Đại học Bách Khoa – ĐHQG-HCM · Khoa Khoa học và Kỹ thuật Máy tính
Học kỳ 261, năm học 2026–2027 · Giảng viên: Lê Thành Sách

Thông tin nhóm

Tên nhóm	**BugIsFeature** (làm cá nhân)
Thành viên	**Nguyễn Thị Cẩm Vân – 2570803** – thực hiện toàn bộ 2 bài
GitHub	vannguyentc-gif
Repository	CO5177-Data-Analysis-and-Visulization
PDF tổng hợp LMS	BugIsFeature-report.pdf

Các bài tập lớn con

Tabular · Bắt buộc

Bài 1 – Dự đoán xe "lemon" trong đấu giá xe cũ

72.983 mẫu × 33 cột; mất cân bằng lớp (12%), missing, outlier. So sánh LogReg / RandomForest / HistGB, xử lý imbalance, chỉnh ngưỡng, feature importance.

Xem báo cáo · Notebook · Colab · PDF report

Video YouTube: chưa cập nhật

Time series · Tự chọn

Bài 2 – Dự báo CO_2 Mauna Loa (12 tuần tới)

2.284 điểm tuần, xu hướng + mùa vụ, 59 giá trị thiếu. Chia theo thời gian, so sánh Naive / Seasonal naive / Ridge / RF / HistGB, level vs delta.

Xem báo cáo · Notebook · Colab · PDF report

Video YouTube: chưa cập nhật

🚗 Kicked Car (Lemon) Dataset

Báo cáo EDA & Machine Learning – Dữ liệu bảng (Tabular)

Nền tảng lập trình cho phân tích và trực quan dữ liệu · HK 261, 2026–2027 · GV: Lê Thành Sách

ĐH Bách Khoa – ĐHQG-HCM · Khoa Khoa học và Kỹ thuật Máy tính

Nhóm BugIsFeature · Nguyễn Thị Cẩm Vân · MSSV 2570803

72,983	33	149,271
Samples	Features	Missing cells

12.3%	1:7.1
Lớp Lemon	Tỉ lệ mất cân bằng

1. Mô tả bài toán và tập dữ liệu

Môn: Nền tảng lập trình cho phân tích và trực quan dữ liệu – HK 261 (2026–2027) · **GV:** Lê Thành Sách **Nhóm:** BugIsFeature · **Sinh viên:** Nguyễn Thị Cẩm Vân · **MSSV:** 2570803 **Hình thức:** cá nhân · **Loại dữ liệu:** Tabular (bắt buộc)

- **Nguồn:** OpenML `kick` (cuộc thi Kaggle *Don't Get Kicked!* của Carvana).
- **Bài toán:** phân loại nhị phân `IsBadBuy` – xe mua ở đấu giá có phải "lemon" (lỗi nặng, mua hỏng) hay không.
- **Quy mô:** 72.983 dòng × 33 cột (> 2000 dòng, > 10 cột).
- **Vì sao khó:** (1) **mất cân bằng lớp** (~12% là lemon), (2) **nhiều missing value**, (3) **outlier** ở giá/số km, (4) nhiều cột categorical có **cardinality cao** (Model ~1000 giá trị).
- **Metric chính:** do lớp lệch nên *không* dùng accuracy một mình mà dùng **F1, ROC-AUC, PR-AUC, Balanced Accuracy**.

Quy trình: Mô tả → EDA → Tiền xử lý (missing, outlier, encoding, scaling, split) → Mô hình sklearn → So sánh → Kết luận.

```
Kích thước: (72983, 33)
```

	IsBadBuy	PurchDate	Auction	VehYear	VehicleAge	Make	Model	Trim
0	0	2009-12-07	ADESA	2006	3	MAZDA	MAZDA3	i
1	0	2009-12-07	ADESA	2004	5	DODGE	1500 RAM PICKUP 2WD	ST
2	0	2009-12-07	ADESA	2005	4	DODGE	STRATUS V6	SXT
3	0	2009-12-07	ADESA	2004	5	DODGE	NEON	SXT
4	0	2009-12-07	ADESA	2005	4	FORD	FOCUS	ZX3

2. Khám phá dữ liệu (EDA)

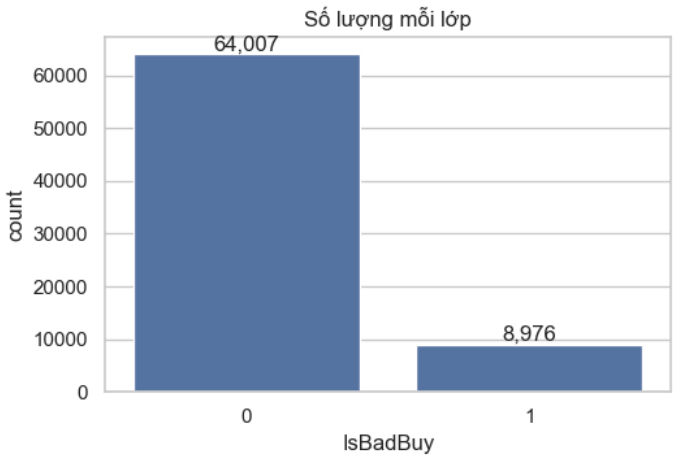
2.1 Tổng quan và kiểu dữ liệu

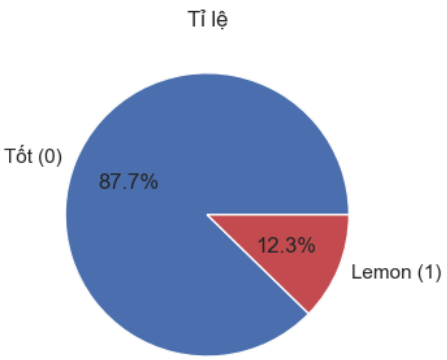
	dtype	n_unique	missing	missing_%
IsBadBuy	int64	2	0	0.00
PurchDate	datetime64[s]	517	0	0.00
Auction	object	3	0	0.00
VehYear	int64	10	0	0.00
VehicleAge	int64	10	0	0.00
Make	object	33	0	0.00
Model	object	1063	0	0.00
Trim	object	134	2360	3.23
SubModel	object	863	8	0.01
Color	object	16	8	0.01
Transmission	object	3	9	0.01
WheelTypeID	object	4	3169	4.34
WheelType	object	3	3174	4.35
VehOdo	int64	39947	0	0.00
Nationality	object	4	5	0.01
Size	object	12	5	0.01
TopThreeAmericanName	object	4	5	0.01
MMRAcquisitionAuctionAveragePrice	float64	10342	18	0.02
MMRAcquisitionAuctionCleanPrice	float64	11379	18	0.02
MMRAcquisitionRetailAveragePrice	float64	12725	18	0.02
MMRAcquisitonRetailCleanPrice	float64	13456	18	0.02
MMRCurrentAuctionAveragePrice	float64	10315	315	0.43
MMRCurrentAuctionCleanPrice	float64	11265	315	0.43
MMRCurrentRetailAveragePrice	float64	12493	315	0.43
MMRCurrentRetailCleanPrice	float64	13192	315	0.43
PRIMEUNIT	object	2	69564	95.32
AUCGUART	object	2	69564	95.32
BYRNO	object	74	0	0.00
VNZIP1	object	153	0	0.00
VNST	object	37	0	0.00
VehBCost	float64	2010	68	0.09

	dtype	n_unique	missing	missing_%
IsOnlineSale	object	2	0	0.00
WarrantyCost	int64	281	0	0.00

	count	mean	min	25%	50
IsBadBuy	72983.0	0.122988	0.0	0.0	0
PurchDate	72983	2010-01-10 02:51:53	2009-01-05 00:00:00	2009-07-20 00:00:00	201 01-2 00:00:0
VehYear	72983.0	2005.343052	2001.0	2004.0	2005
VehicleAge	72983.0	4.176644	0.0	3.0	4
VehOdo	72983.0	71499.995917	4825.0	61837.0	73361
MMRAcquisitionAuctionAveragePrice	72965.0	6128.909217	0.0	4273.0	6097
MMRAcquisitionAuctionCleanPrice	72965.0	7373.636031	0.0	5406.0	7303
MMRAcquisitionRetailAveragePrice	72965.0	8497.034332	0.0	6280.0	8444
MMRAcquisitonRetailCleanPrice	72965.0	9850.92824	0.0	7493.0	9789
MMRCurrentAuctionAveragePrice	72668.0	6132.081287	0.0	4275.0	6062
MMRCurrentAuctionCleanPrice	72668.0	7390.681827	0.0	5414.0	7313
MMRCurrentRetailAveragePrice	72668.0	8775.723331	0.0	6536.0	8729
MMRCurrentRetailCleanPrice	72668.0	10145.385314	0.0	7784.0	10103
VehBCost	72915.0	6729.249949	1.0	5430.0	6700
WarrantyCost	72983.0	1276.580985	462.0	837.0	1155

2.2 Phân phối biến mục tiêu (mất cân bằng lớp)



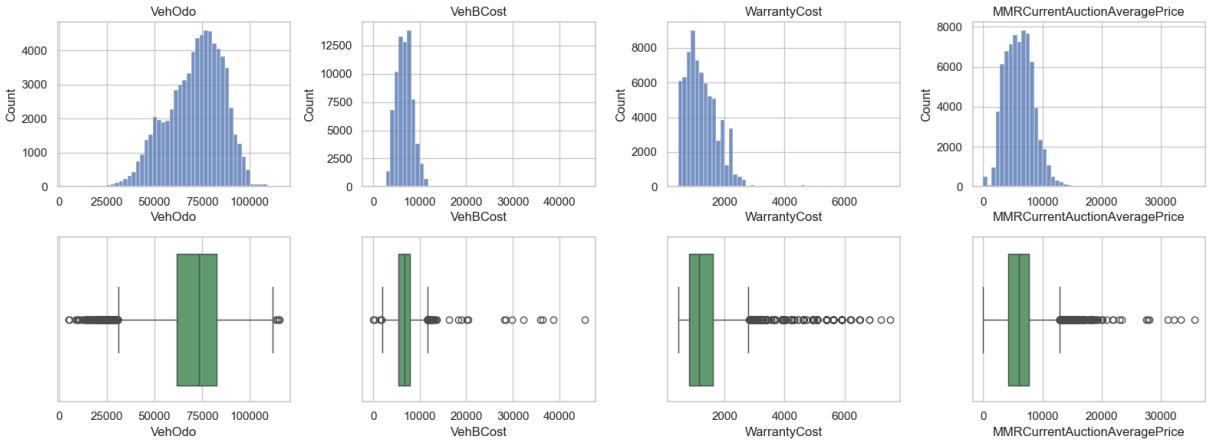


Kết luận: lớp lemon chỉ chiếm **12.3%** (tỉ lệ 1:7.1). Một mô hình luôn đoán 'tốt' đã đạt accuracy **87.7%** nhưng vô dụng -> phải dùng F1/PR-AUC và xử lý imbalance.

2.3 Missing values

Kết luận: có **20/33** cột bị thiếu, tổng **149,271** ô. `PRIMEUNIT` (95.3%) và `AUCGUART` (95.3%) gần như trống -> thiếu có thể mang ý nghĩa (xe không được bảo đảm) nên ta tạo cờ `is_missing` thay vì chỉ điền.

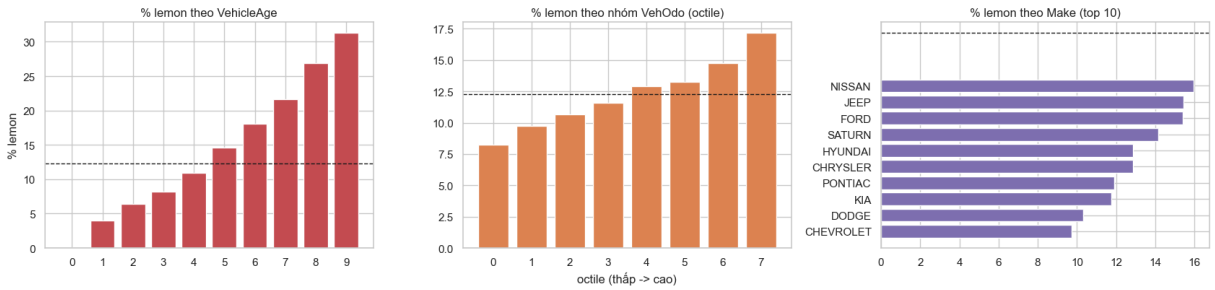
2.4 Numerical: phân phối và outlier



	% outlier theo IQR
VehOdo	0.46
VehBCost	0.24
WarrantyCost	1.15
MMRCurrentAuctionAveragePrice	0.78

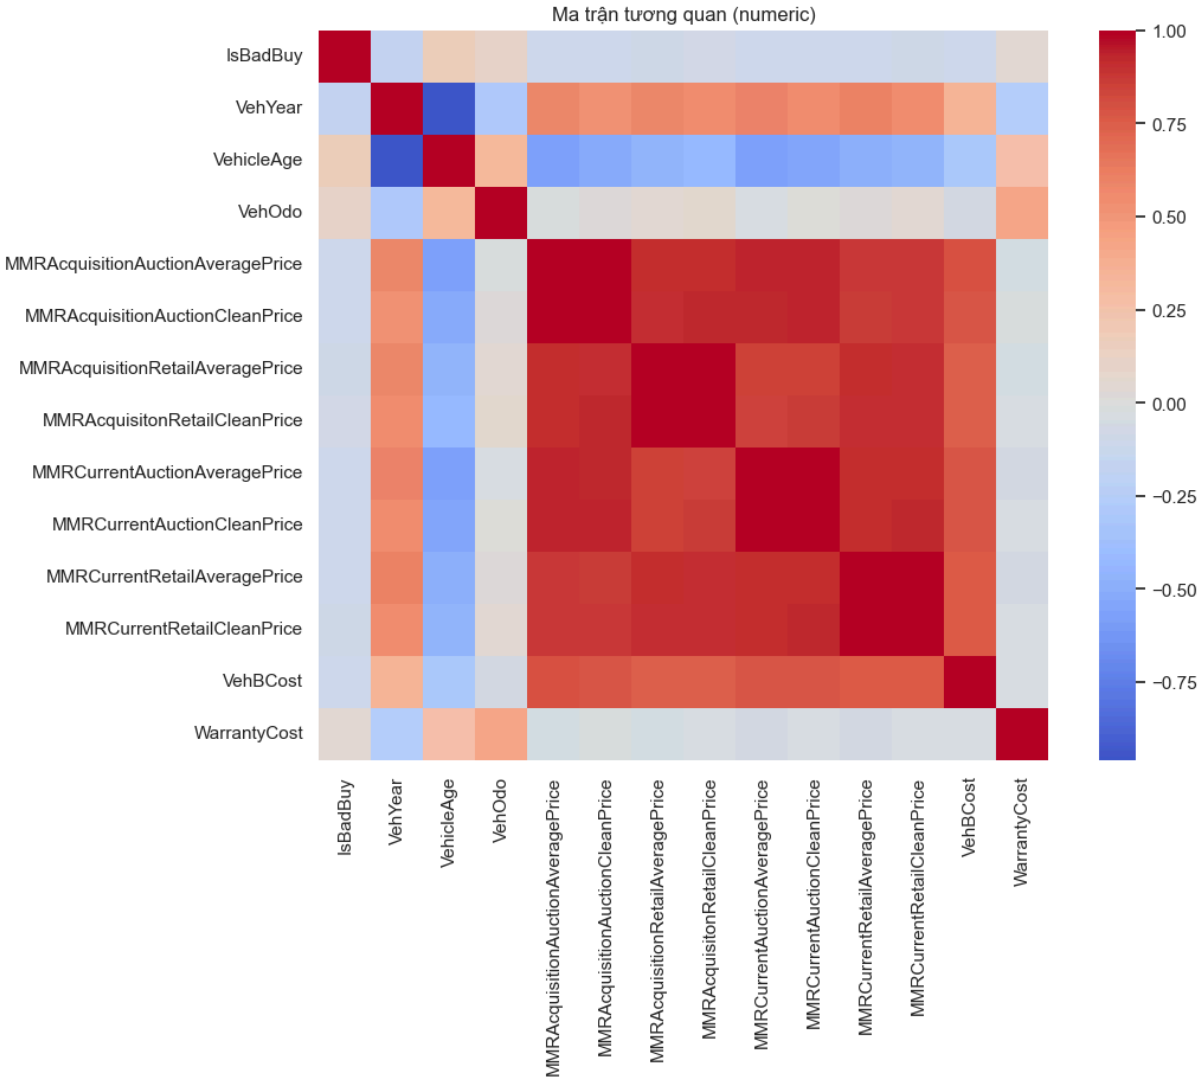
Kết luận: `WarrantyCost` có đuôi phải dài (outlier 1.15%). Nên dùng **RobustScaler** (median/IQR) thay vì StandardScaler để outlier không kéo lệch thang đo.

2.5 Mục tiêu so với các feature (target vs 2–3 feature)



Kết luận: xe càng **già** và chạy càng **nhiều km** thì tỉ lệ lemon càng cao: từ **0.0%** (tuổi 0) lên **31.3%** (tuổi 9); octile km thấp nhất **8.2%** vs cao nhất **17.2%**. Hãng cũng khác biệt (từ 9.7% đến 16.0%). Đường nét đứt = mức trung bình toàn bộ.

2.6 Tương quan giữa các biến số



Kết luận: 8 cột `MMR*` tương quan gần nhau (|r| lên tới **0.99**) -> đa cộng tuyến, ảnh hưởng mô hình tuyến tính. Tương quan tuyến tính với target đều yếu (cao nhất: `VehicleAge` r=0.17) -> cần mô hình phi tuyến.

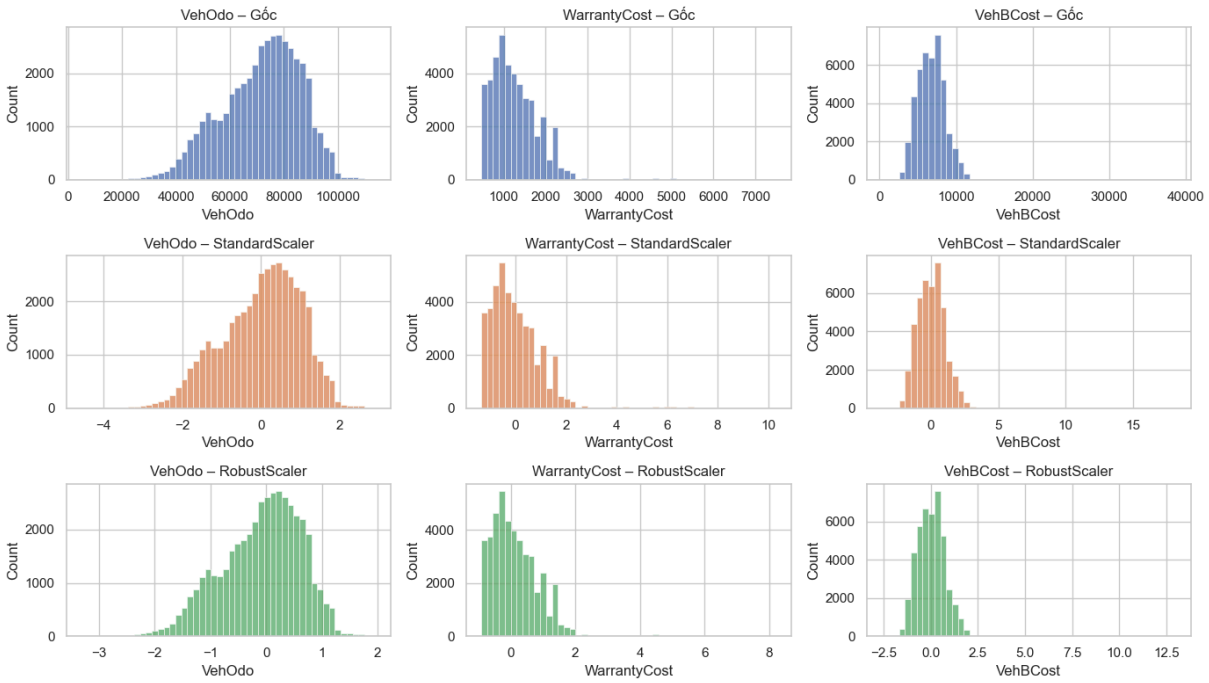
3. Chuẩn bị dữ liệu

1. **Feature engineering:** tách `PurchDate` thành năm/tháng; tạo `age_odo = VehOdo/(VehicleAge+1)`, chênh lệch giá `Acq_vs_Cur = MMRAcquisitionAuctionAveragePrice - MMRCurrentAuctionAveragePrice`, `Cost_vs_MMR = VehBCost / MMRCurrentAuctionAveragePrice`; cờ missing cho `PRIMEUNIT`, `AUCGUART`.
2. **Split 60/20/20 train/val/test, stratify theo target** (split *trước* khi fit bất kỳ bộ biến đổi nào -> tránh data leakage).
3. **Missing:** numeric -> median (fit trên train); categorical -> `"missing"`.
4. **Outlier:** giữ nguyên giá trị nhưng dùng RobustScaler (và cây quyết định vốn bền với outlier).
5. **Encoding:** cardinality ≤ 20 -> One-Hot; cardinality cao (Model, Trim, SubModel, BYRNO, VNZIP1, VNST, Make) -> **Frequency encoding** (fit trên train).
6. **Scaling:** RobustScaler cho numeric.

```
{'train': (43789, np.float64(0.123)), 'val': (14597, np.float64(0.123)), 'test': (1
4597, np.float64(0.123))}

numeric: 20 | low-card cat: ['Auction', 'Color', 'Transmission', 'WheelTypeID', 'Wh
eelType', 'Nationality', 'Size', 'TopThreeAmericanName', 'PRIMEUNIT', 'AUCGUART',
'IsOnlineSale']
high-card cat: ['Make', 'Model', 'Trim', 'SubModel', 'BYRNO', 'VNZIP1', 'VNST']
Số feature sau tiền xử lý: 86
```

3.1 So sánh phân phối trước/sau scaling



Kết luận: với `WarrantyCost`, độ lệch chuẩn = **602** trong khi 'sigma theo IQR' = **571** (tỉ lệ 1.05). Tỉ lệ > 1 nghĩa là outlier làm phồng độ lệch chuẩn nên StandardScaler nén phần lớn dữ liệu vào vùng hẹp hơn; RobustScaler chuẩn hóa theo median/IQR nên không bị outlier chi phối. Cả hai đều giữ nguyên hình dạng phân phối (lệch phải), chỉ đổi thang đo.

4. Mô hình hóa

Huấn luyện 6 cấu hình để so sánh có chủ đích:

#	Mô hình	Mục đích
A	Logistic Regression (baseline)	Mốc tham chiếu
B	Logistic Regression + `class_weight=balanced`	Tác động của xử lý imbalance
C	Random Forest + `class_weight=balanced_subsample`	Mô hình phi tuyến
D	HistGradientBoosting (không xử lý imbalance)	Boosting
E	HistGradientBoosting + `class_weight=balanced`	Boosting + imbalance
F	E + **chỉnh ngưỡng** theo F1 trên validation	Ngưỡng 0.5 không phù hợp lớp hiếm

```
== Validation ==
```

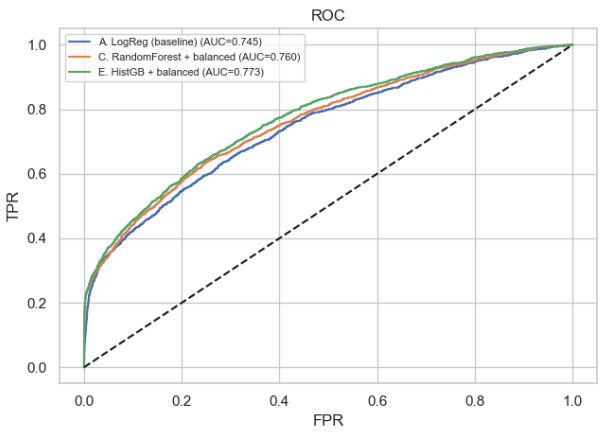
model	thr	accuracy	balanced_acc	precision	recall	F1	ROC_AUC
A. LogReg (baseline)	0.500	0.8955	0.6094	0.7415	0.2301	0.3512	0.7585
B. LogReg + balanced	0.500	0.7460	0.6909	0.2685	0.6178	0.3743	0.7623
C. RandomForest + balanced	0.500	0.8952	0.6354	0.6701	0.2908	0.4056	0.7737
D. HistGB	0.500	0.9025	0.6180	0.8780	0.2407	0.3778	0.7825
E. HistGB + balanced	0.500	0.7766	0.7062	0.3001	0.6128	0.4029	0.7819
F. HistGB + balanced + tuned thr	0.611	0.8585	0.6875	0.4296	0.4607	0.4446	0.7819

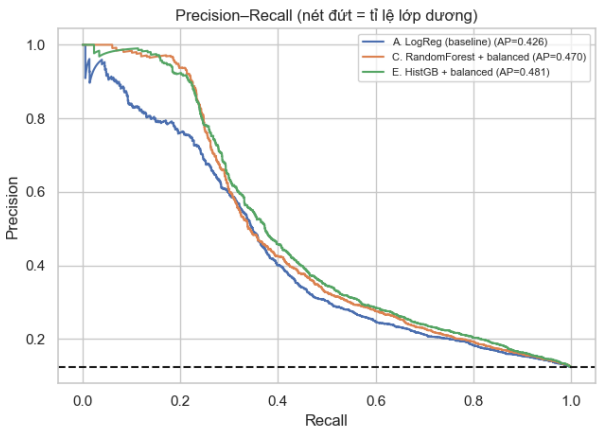
```
== Test ==
```

model	thr	accuracy	balanced_acc	precision	recall	F1	RO
A. LogReg (baseline)	0.500000	0.894700	0.609000	0.727100	0.230100	0.349600	0.
B. LogReg + balanced	0.500000	0.734700	0.678000	0.255100	0.602800	0.358500	0.
C. RandomForest + balanced	0.500000	0.894100	0.632600	0.660200	0.285800	0.398900	0.
D. HistGB	0.500000	0.902000	0.615600	0.879400	0.235700	0.371700	0.
E. HistGB + balanced	0.500000	0.766900	0.694200	0.285900	0.597800	0.386800	0.
F. HistGB + balanced + tuned thr	0.611000	0.852500	0.675200	0.407600	0.440100	0.423300	0.

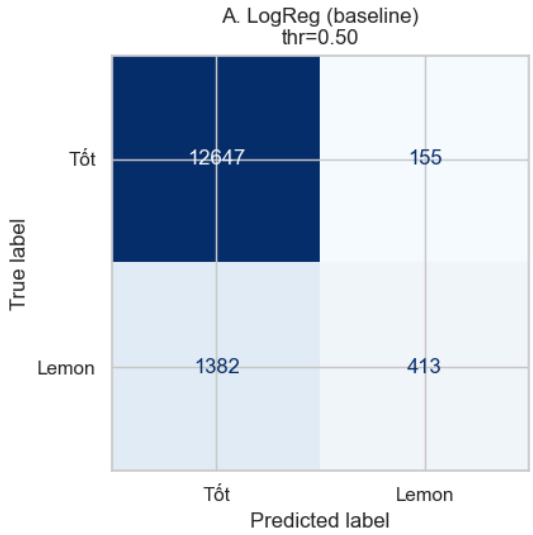
4.1 So sánh mô hình (baseline vs mô hình mở rộng)

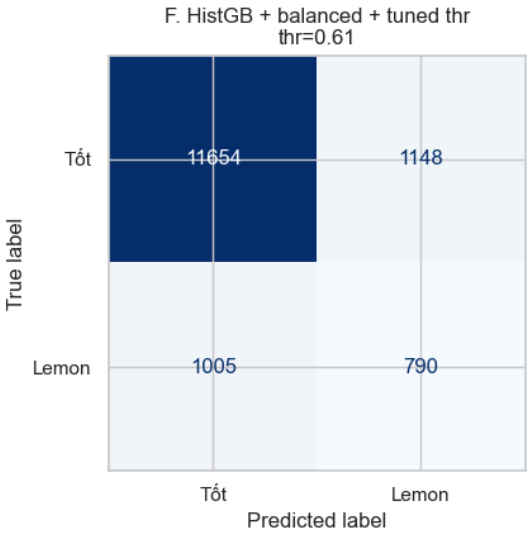
Kết luận: (1) Baseline A có accuracy **0.895** nhưng recall chỉ **0.230** / F1 **0.350** – bị lớp đa số chi phối. (2) `class_weight=balanced` (B) tăng recall lên **0.603** nhưng precision giảm xuống **0.255**. (3) Boosting D đạt PR-AUC **0.493** so với LogReg **0.426**. (4) Chỉnh ngưỡng (F, thr=0.61) cho F1 = **0.423**. Mô hình F1 cao nhất trên test: **F. HistGB + balanced + tuned thr** (F1=0.423).





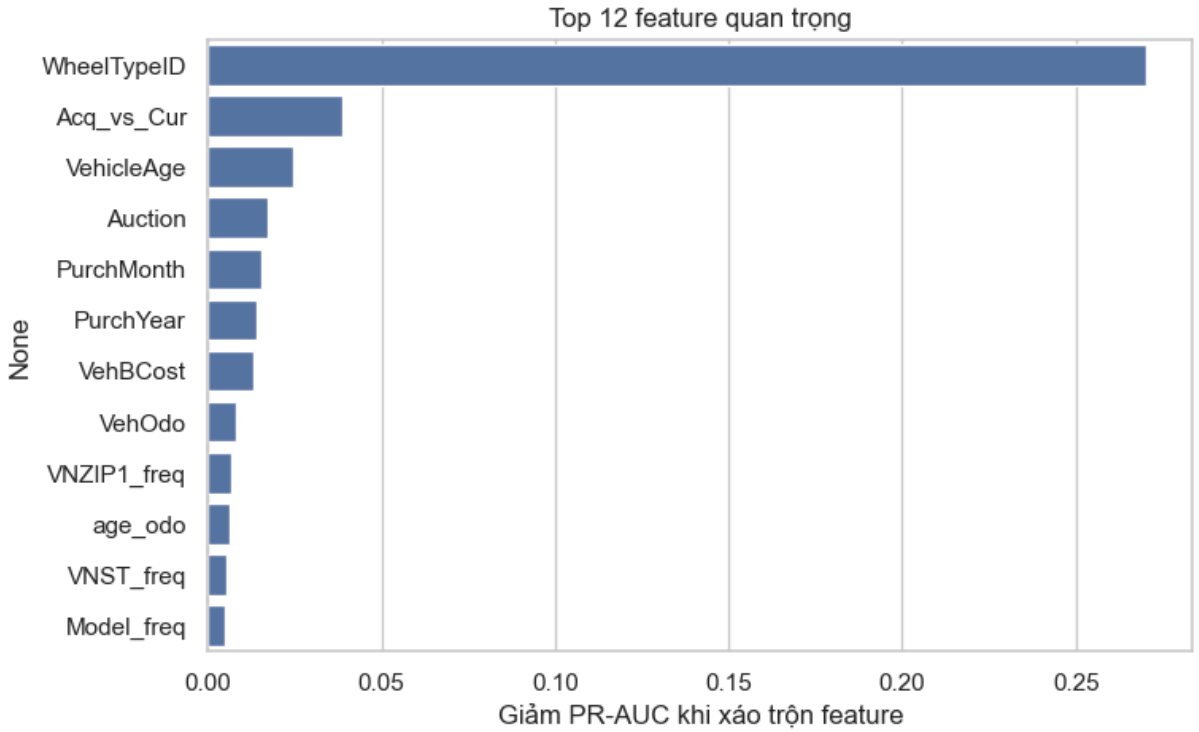
4.2 Confusion matrix: baseline vs mô hình cuối





Kết luận: số lemon bắt được tăng từ **413** (baseline) lên **790** (mô hình cuối) trên tổng **1795** lemon thật; đổi lại số xe tốt bị cảnh báo nhầm tăng từ **155** lên **1148**. Đây là trade-off: chi phí bỏ sót lemon thường cao hơn chi phí kiểm tra thêm xe.

4.3 Feature importance (permutation importance, mô hình E trên test)



Kết luận: 3 feature quan trọng nhất là **WheelTypeID, Acq_vs_Cur, VehicleAge** (giảm PR-AUC 0.270, 0.039, 0.025). Lưu ý `WheelTypeID` (thiếu giá trị ở một nhóm xe) là tín hiệu rất mạnh; cần cẩn trọng vì nếu cách thu thập ID này thay đổi khi triển khai thật thì mô hình sẽ lệch.

5. Tổng kết và mở rộng

Phần này được điền tự động từ bảng metric để kết luận luôn khớp số liệu trong report.

Kết quả chính (tập test, 14,597 mẫu)

Mô hình	F1	Recall	PR-AUC	ROC-AUC
A. LogReg (baseline)	0.350	0.230	0.426	0.745
B. LogReg + balanced	0.358	0.603	0.421	0.747
C. RandomForest + balanced	0.399	0.286	0.470	0.760
D. HistGB	0.372	0.236	0.493	0.775
E. HistGB + balanced	0.387	0.598	0.481	0.773
F. HistGB + balanced + tuned thr	0.423	0.440	0.481	0.773

- **Mô hình tốt nhất theo PR-AUC:** D. HistGB (0.493); theo F1: F. HistGB + balanced + tuned thr (0.423).
- So với baseline: F1 **0.350** → **0.423** (gấp 1.2 lần), recall **0.230** → **0.440**.
- **Accuracy gây hiểu lầm:** baseline accuracy 0.895 cao nhưng F1 thấp, do dữ liệu lệch lớp.

Hạn chế

- ROC-AUC/PR-AUC vẫn ở mức vừa phải -> dữ liệu có nhiễu, thông tin trong bảng không đủ phân biệt hoàn toàn (không có thông tin kiểm định cơ khí).
- Frequency encoding làm mất thông tin về *danh tính* của Model/Trim; chưa tinh chỉnh siêu tham số (chỉ dùng mặc định).
- Chia ngẫu nhiên, chưa kiểm tra drift theo thời gian (`PurchDate`).

Hướng mở rộng

- Target encoding có cross-fitting; tối ưu siêu tham số (RandomizedSearchCV); SMOTE / cost-sensitive threshold theo chi phí kinh doanh thật.
- Chia theo thời gian để kiểm tra mô hình có bền khi triển khai; SHAP để giải thích từng dự đoán.

🌍 Mauna Loa CO_2 Dataset

Báo cáo EDA & Dự báo – Dữ liệu chuỗi thời gian (Time series)

Nền tảng lập trình cho phân tích và trực quan dữ liệu · HK 261, 2026–2027 · GV: Lê Thành Sách

ĐH Bách Khoa – ĐHQG-HCM · Khoa Khoa học và Kỹ thuật Máy tính

Nhóm BugIsFeature · Nguyễn Thị Cẩm Vân · MSSV 2570803

2,284	1958–2001	59
Điểm (tuần)	Khoảng thời gian	Giá trị thiếu

12 tuần	~1.3 ppm/năm
Horizon dự báo	Xu hướng

1. Mô tả bài toán và tập dữ liệu

Môn: Nền tảng lập trình cho phân tích và trực quan dữ liệu – HK 261 (2026–2027) · **GV:** Lê Thành Sách **Nhóm:** BugIsFeature · **Sinh viên:** Nguyễn Thị Cẩm Vân · **MSSV:** 2570803 **Hình thức:** cá nhân · **Loại dữ liệu:** Time series (tự chọn)

- **Nguồn:** `statsmodels.datasets.co2` – đo CO_2 hàng tuần tại Mauna Loa (Scripps), 03/1958 – 12/2001, **2284 điểm**, có **59 giá trị thiếu**.
- **Đặc điểm:** *xu hướng tăng dài hạn + mùa vụ hàng năm* (chu kỳ 52 tuần).
- **Bài toán:** dự báo **12 tuần tới** (horizon h=12) – hồi quy.
- **Nguyên tắc:** chia train/val/test **theo thời gian** (không shuffle), mọi biến đổi chỉ dùng thông tin quá khứ để tránh data leakage.
- **Metric:** MAE, RMSE, MAPE.

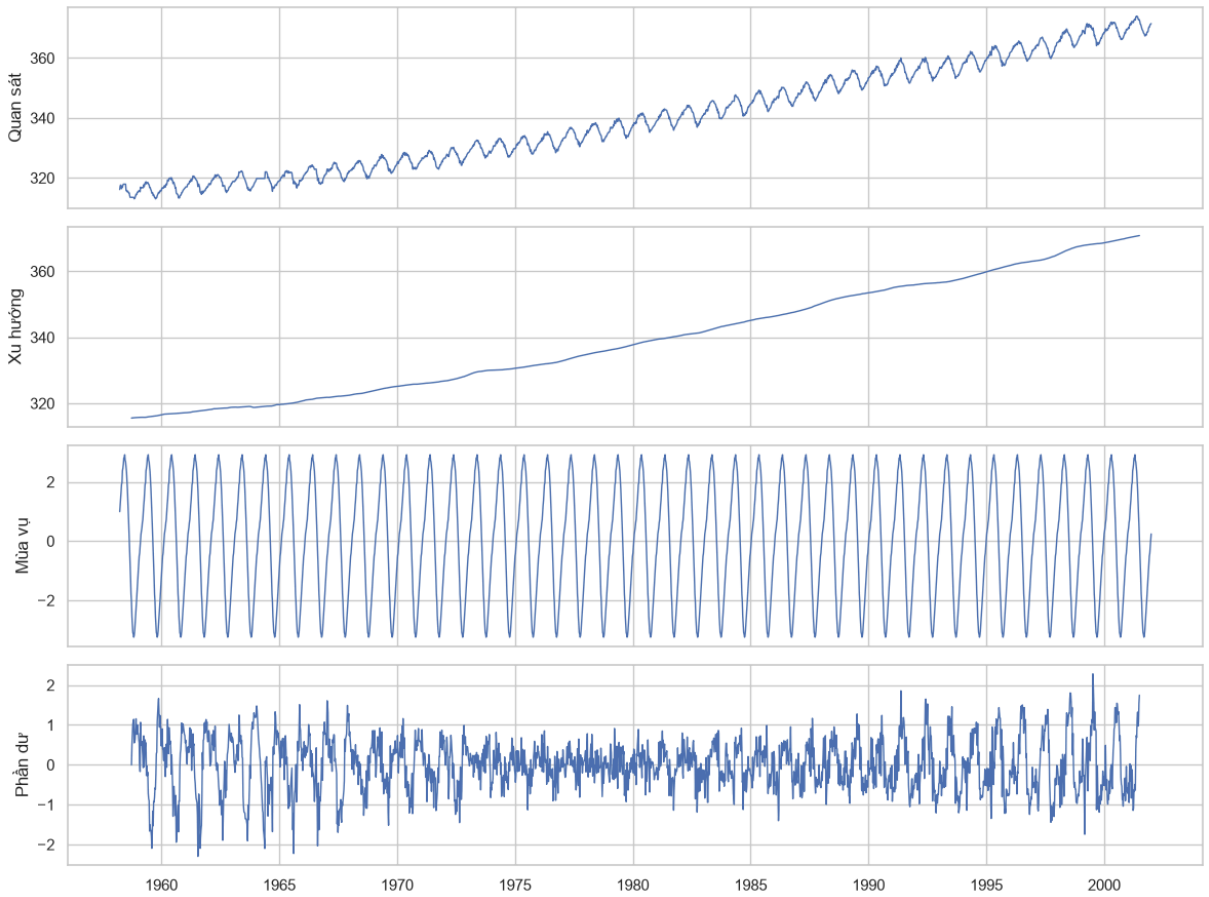
```
(2284,) | thiếu: 59 | tần suất: W-SAT
1958-03-29    316.1
1958-04-05    317.3
1958-04-12    317.6
1958-04-19    317.5
1958-04-26    316.4
Freq: W-SAT, Name: co2, dtype: float64
```

2. Khám phá dữ liệu (EDA)

2.1 Chuỗi gốc và missing

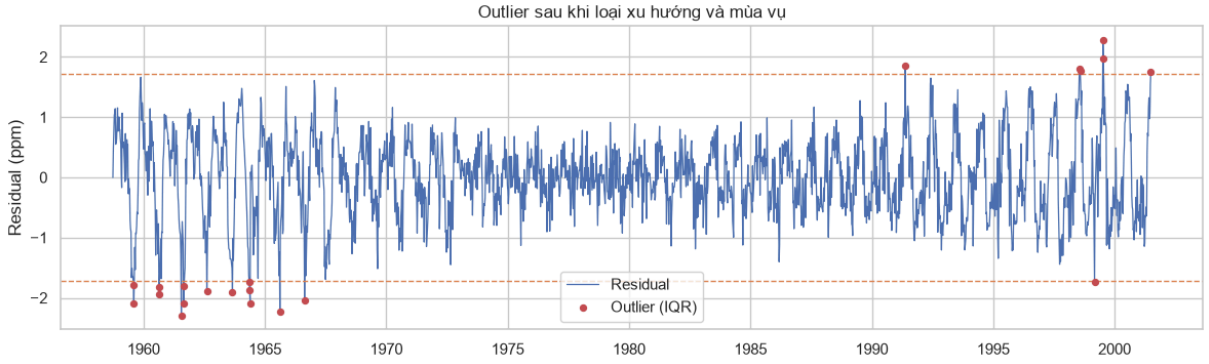
Kết luận: CO_2 tăng từ **316.1** lên **371.5 ppm** (+55.4) trong 44 năm, kèm dao động mùa vụ đều đặn. Có **59** tuần thiếu (2.6%) tạo thành **22** khoảng trống.

2.2 Phân rã xu hướng – mùa vụ – phần dư



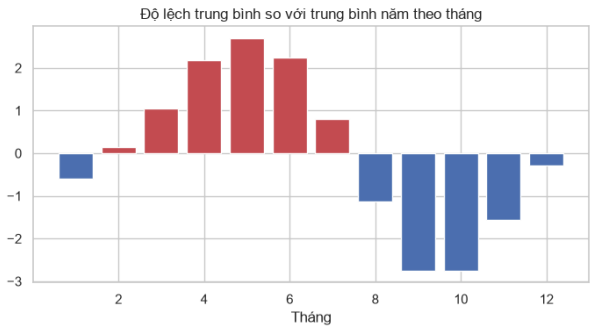
Kết luận: biên độ mùa vụ ≈ **6.2 ppm**, xu hướng tăng ≈ **1.29 ppm/năm**; mùa vụ chỉ giải thích **1.3%** phương sai so với xu hướng. => Mô hình phải *ngoại suy được xu hướng tăng* thì mới dự báo tốt.

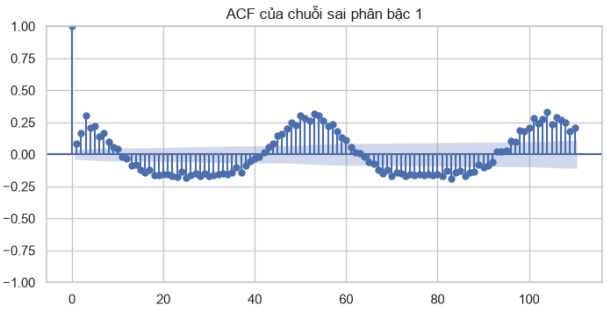
2.3 Phát hiện outlier trên phần dư mùa vụ



Kết luận: phát hiện **21** điểm bất thường (0.94%) ngoài khoảng IQR [-1.72, 1.72] ppm. Không xóa các điểm này vì có thể là biến động khí quyển thật; mô hình cây và metric MAE tương đối bền với outlier. Phần missing vẫn được forward-fill ở bước chuẩn bị dữ liệu.

2.4 Mùa vụ theo tháng và tự tương quan





Kết luận: CO_2 đạt đỉnh vào tháng **5** (+2.70 ppm) và đáy vào tháng **10** (-2.75 ppm) – phù hợp chu kỳ quang hợp của thực vật bán cầu Bắc. ACF có đỉnh quanh lag 52 xác nhận chu kỳ năm -> nên đưa **lag 52** và **sin/cos tuần trong năm** vào feature.

3. Chuẩn bị dữ liệu

1. **Missing:** *forward-fill* (chỉ dùng quá khứ, không rò rỉ tương lai; nội suy tuyến tính sẽ dùng giá trị tương lai).
2. **Feature:** lag 1,2,3,4,8,12,26,52; trung bình trượt 4/12/52 tuần (dịch 0, tính trên quá khứ đến thời điểm t); sin/cos tuần trong năm; chỉ số thời gian `t` (xu hướng).
3. **Target:** giá trị tại **t+12**.
4. **Split theo thời gian:** 70% train / 15% val / 15% test (không shuffle). Với horizon h, hàng cuối cùng của mỗi tập được loại để target không chồng sang tập sau.
5. **Scaling:** StandardScaler fit trên train (cho mô hình tuyến tính).

```
{'train': (1542, '1959-03-21', '1988-10-01'), 'val': (321, '1988-12-31', '1995-02-1
8'), 'test': (334, '1995-05-20', '2001-10-06')}
```

Kết luận: test (1995–2001) nằm hoàn toàn *sau* train, nên đánh giá mô phỏng đúng tình huống dự báo thực tế. Giá trị CO_2 trên test (trung bình 366.1) cao hơn hẳn train (330.8) -> mô hình bị thử thách khi **ngoại suy xu hướng**.

4. Mô hình hóa

Mô hình	Ý tưởng
Naive	dự báo = giá trị hiện tại
Seasonal naive	= giá trị cùng thời điểm năm trước của mốc dự báo (t+12−52)
Ridge (level)	hồi quy tuyến tính dự báo trực tiếp *mức* CO_2
RandomForest (level)	cây quyết định dự báo *mức* – không ngoại suy được
HistGB (level)	tương tự với boosting
RandomForest (delta)	dự báo **mức thay đổi** `y[t+12] - y[t]` rồi cộng lại giá trị hiện tại
HistGB (delta)	tương tự
Ridge (delta)	tương tự

```
alpha Ridge chọn từ validation: 0.1
```

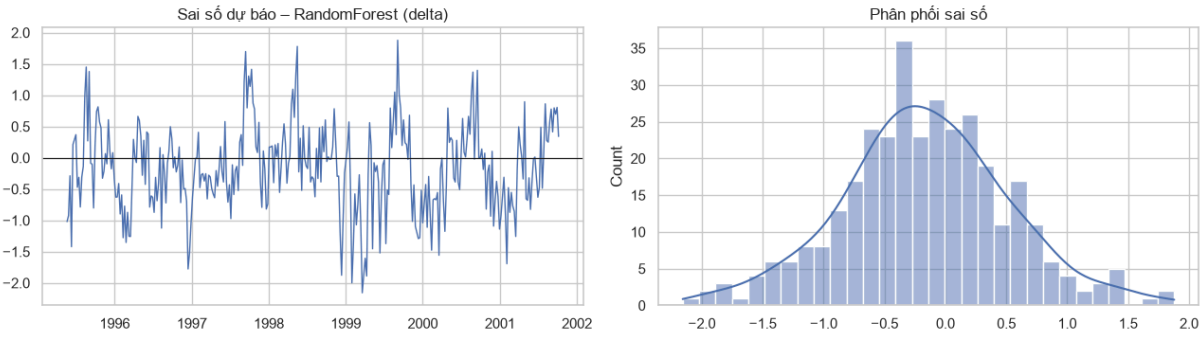
model	MAE	RMSE	MAPE_pct
RandomForest (delta)	0.555000	0.709000	0.151000
HistGB (delta)	0.586000	0.735000	0.160000
Ridge (delta)	0.597000	0.757000	0.163000
Ridge (level)	0.601000	0.759000	0.164000
Seasonal naive + drift	0.651000	0.825000	0.178000
Seasonal naive	1.684000	1.881000	0.460000
Naive	2.769000	3.071000	0.757000
HistGB (level)	15.050000	15.410000	4.099000
RandomForest (level)	16.023000	16.409000	4.363000

4.1 So sánh mô hình: dự báo *level* và *delta*

Kết luận: mô hình tốt nhất là **RandomForest (delta)** (MAE **0.555** ppm, MAPE 0.151%); kém nhất: **RandomForest (level)** (MAE 16.023). Cùng một RandomForest, đổi mục tiêu từ *level* sang *delta* làm MAE giảm **16.023** → **0.555** (giảm 97%) – vì cây không thể dự đoán giá trị lớn hơn mọi giá trị đã thấy trong train, còn dự báo *mức thay đổi* thì không bị giới hạn. So với Naive (MAE 2.769), mô hình tốt nhất giảm sai số 80%.

4.2 Dự báo so với thực tế (tập test)

Kết luận: RandomForest (level) dự báo **thấp hơn thực tế một cách hệ thống** (sai số trung bình +16.02 ppm, nghĩa là luôn thấp hơn), đường dự báo bị 'phẳng' ở mức tối đa đã thấy trong train (354.5 ppm). Mô hình **RandomForest (delta)** bám sát đường thực tế cả xu hướng lẫn mùa vụ (sai số trung bình -0.173 ppm).



Kết luận: sai số khá cân quanh 0 (độ lệch chuẩn 0.689 ppm). Tháng khó dự báo nhất là **tháng 12** (|sai số| TB 0.797), dễ nhất là **tháng 10** (0.406) – thường là các tháng chuyển pha mùa vụ (đỉnh/đáy) nên khó hơn.

4.3 Độ ổn định theo horizon (mở rộng)

Kiểm tra mô hình tốt nhất khi horizon dài hơn (4, 12, 26, 52 tuần) so với Naive.

horizon_weeks	naive_MAE	RF_delta_MAE
4	1.108	0.454
12	2.769	0.557
26	3.733	0.687
52	1.678	0.945

Kết luận: sai số của cả hai tăng theo horizon, nhưng RF (delta) tăng chậm hơn: ở h=52, MAE **0.945** vs Naive **1.678** (giảm 44%). Mô hình tận dụng được mùa vụ nên lợi thế so với Naive lớn dần khi dự báo xa.

5. Tổng kết và mở rộng

Kết quả (test, horizon 12 tuần, 334 mẫu)

Mô hình	MAE	RMSE	MAPE %
RandomForest (delta)	0.555	0.709	0.151
HistGB (delta)	0.586	0.735	0.160
Ridge (delta)	0.597	0.757	0.163
Ridge (level)	0.601	0.759	0.164
Seasonal naive + drift	0.651	0.825	0.178
Seasonal naive	1.684	1.881	0.460
Naive	2.769	3.071	0.757
HistGB (level)	15.050	15.410	4.099
RandomForest (level)	16.023	16.409	4.363

- **Mô hình tốt nhất:** RandomForest (delta) – MAE 0.555 ppm, so với Naive 2.769.
- **Bài học chính:** với chuỗi có xu hướng, mô hình cây dự báo *mức* sẽ thất bại khi ngoại suy (MAE 16.023); dự báo *mức thay đổi* (delta) giải quyết được (MAE 0.555).
- Split theo thời gian + forward-fill bảo đảm không rò rỉ tương lai.

Hạn chế

- Chỉ một chuỗi đơn biến; chưa dùng mô hình thống kê chuyên dụng (SARIMA, ETS, Prophet) để đối chiếu.
- Một lần chia train/val/test; chưa dùng walk-forward CV đầy đủ. Siêu tham số cây để mặc định.
- Dữ liệu dừng ở 2001 – chưa phản ánh giai đoạn tăng tốc sau đó.

Hướng mở rộng

- So sánh với SARIMA/ETS; walk-forward `TimeSeriesSplit`; khoảng tin cậy dự báo (quantile regression).
- Thêm biến ngoại sinh (ENSO, phát thải) và áp dụng cho chuỗi cập nhật mới nhất của NOAA.

Bài tập lớn môn Nền tảng lập trình cho phân tích và trực quan dữ liệu.