🚗 Kicked Car (Lemon) Dataset

Báo cáo EDA & Machine Learning – Dữ liệu bảng (Tabular)

Nền tảng lập trình cho phân tích và trực quan dữ liệu · HK 261, 2026–2027 · GV: Lê Thành Sách

ĐH Bách Khoa – ĐHQG-HCM · Khoa Khoa học và Kỹ thuật Máy tính

Nhóm BugIsFeature · Nguyễn Thị Cẩm Vân · MSSV 2570803

72,983	33	149,271
Samples	Features	Missing cells

12.3%	1:7.1
Lớp Lemon	Tỉ lệ mất cân bằng

1. Mô tả bài toán và tập dữ liệu

Môn: Nền tảng lập trình cho phân tích và trực quan dữ liệu – HK 261 (2026–2027) · **GV:** Lê Thành Sách **Nhóm:** BugIsFeature · **Sinh viên:** Nguyễn Thị Cẩm Vân · **MSSV:** 2570803 **Hình thức:** cá nhân · **Loại dữ liệu:** Tabular (bắt buộc)

- **Nguồn:** OpenML `kick` (cuộc thi Kaggle *Don't Get Kicked!* của Carvana).
- **Bài toán:** phân loại nhị phân `IsBadBuy` – xe mua ở đấu giá có phải "lemon" (lỗi nặng, mua hỏng) hay không.
- **Quy mô:** 72.983 dòng × 33 cột (> 2000 dòng, > 10 cột).
- **Vì sao khó:** (1) **mất cân bằng lớp** (~12% là lemon), (2) **nhiều missing value**, (3) **outlier** ở giá/số km, (4) nhiều cột categorical có **cardinality cao** (Model ~1000 giá trị).
- **Metric chính:** do lớp lệch nên *không* dùng accuracy một mình mà dùng **F1, ROC-AUC, PR-AUC, Balanced Accuracy**.

Quy trình: Mô tả → EDA → Tiền xử lý (missing, outlier, encoding, scaling, split) → Mô hình sklearn → So sánh → Kết luận.

```
Kích thước: (72983, 33)
```

	IsBadBuy	PurchDate	Auction	VehYear	VehicleAge	Make	Model	Trim
0	0	2009-12-07	ADESA	2006	3	MAZDA	MAZDA3	i
1	0	2009-12-07	ADESA	2004	5	DODGE	1500 RAM PICKUP 2WD	ST
2	0	2009-12-07	ADESA	2005	4	DODGE	STRATUS V6	SXT
3	0	2009-12-07	ADESA	2004	5	DODGE	NEON	SXT
4	0	2009-12-07	ADESA	2005	4	FORD	FOCUS	ZX3

2. Khám phá dữ liệu (EDA)

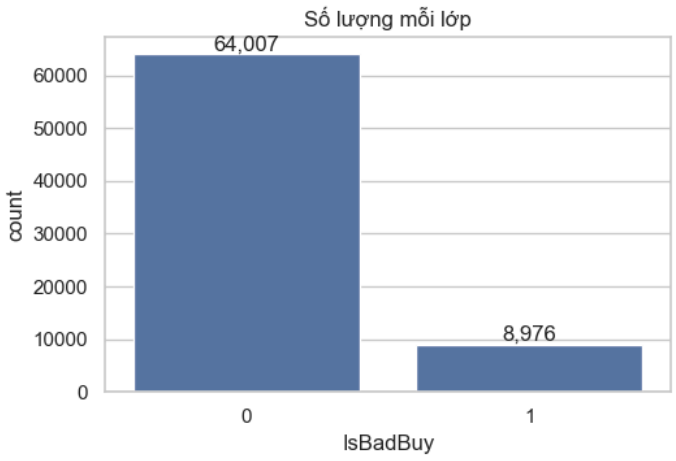
2.1 Tổng quan và kiểu dữ liệu

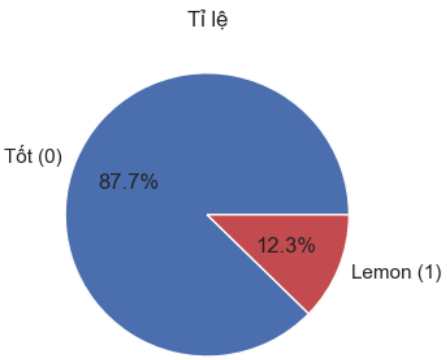
	dtype	n_unique	missing	missing_%
IsBadBuy	int64	2	0	0.00
PurchDate	datetime64[s]	517	0	0.00
Auction	object	3	0	0.00
VehYear	int64	10	0	0.00
VehicleAge	int64	10	0	0.00
Make	object	33	0	0.00
Model	object	1063	0	0.00
Trim	object	134	2360	3.23
SubModel	object	863	8	0.01
Color	object	16	8	0.01
Transmission	object	3	9	0.01
WheelTypeID	object	4	3169	4.34
WheelType	object	3	3174	4.35
VehOdo	int64	39947	0	0.00
Nationality	object	4	5	0.01
Size	object	12	5	0.01
TopThreeAmericanName	object	4	5	0.01
MMRAcquisitionAuctionAveragePrice	float64	10342	18	0.02
MMRAcquisitionAuctionCleanPrice	float64	11379	18	0.02
MMRAcquisitionRetailAveragePrice	float64	12725	18	0.02
MMRAcquisitonRetailCleanPrice	float64	13456	18	0.02
MMRCurrentAuctionAveragePrice	float64	10315	315	0.43
MMRCurrentAuctionCleanPrice	float64	11265	315	0.43
MMRCurrentRetailAveragePrice	float64	12493	315	0.43
MMRCurrentRetailCleanPrice	float64	13192	315	0.43
PRIMEUNIT	object	2	69564	95.32
AUCGUART	object	2	69564	95.32
BYRNO	object	74	0	0.00
VNZIP1	object	153	0	0.00
VNST	object	37	0	0.00
VehBCost	float64	2010	68	0.09

	dtype	n_unique	missing	missing_%
IsOnlineSale	object	2	0	0.00
WarrantyCost	int64	281	0	0.00

	count	mean	min	25%	50
IsBadBuy	72983.0	0.122988	0.0	0.0	0
PurchDate	72983	2010-01-10 02:51:53	2009-01-05 00:00:00	2009-07-20 00:00:00	201 01-2 00:00:0
VehYear	72983.0	2005.343052	2001.0	2004.0	2005
VehicleAge	72983.0	4.176644	0.0	3.0	4
VehOdo	72983.0	71499.995917	4825.0	61837.0	73361
MMRAcquisitionAuctionAveragePrice	72965.0	6128.909217	0.0	4273.0	6097
MMRAcquisitionAuctionCleanPrice	72965.0	7373.636031	0.0	5406.0	7303
MMRAcquisitionRetailAveragePrice	72965.0	8497.034332	0.0	6280.0	8444
MMRAcquisitonRetailCleanPrice	72965.0	9850.92824	0.0	7493.0	9789
MMRCurrentAuctionAveragePrice	72668.0	6132.081287	0.0	4275.0	6062
MMRCurrentAuctionCleanPrice	72668.0	7390.681827	0.0	5414.0	7313
MMRCurrentRetailAveragePrice	72668.0	8775.723331	0.0	6536.0	8729
MMRCurrentRetailCleanPrice	72668.0	10145.385314	0.0	7784.0	10103
VehBCost	72915.0	6729.249949	1.0	5430.0	6700
WarrantyCost	72983.0	1276.580985	462.0	837.0	1155

2.2 Phân phối biến mục tiêu (mất cân bằng lớp)



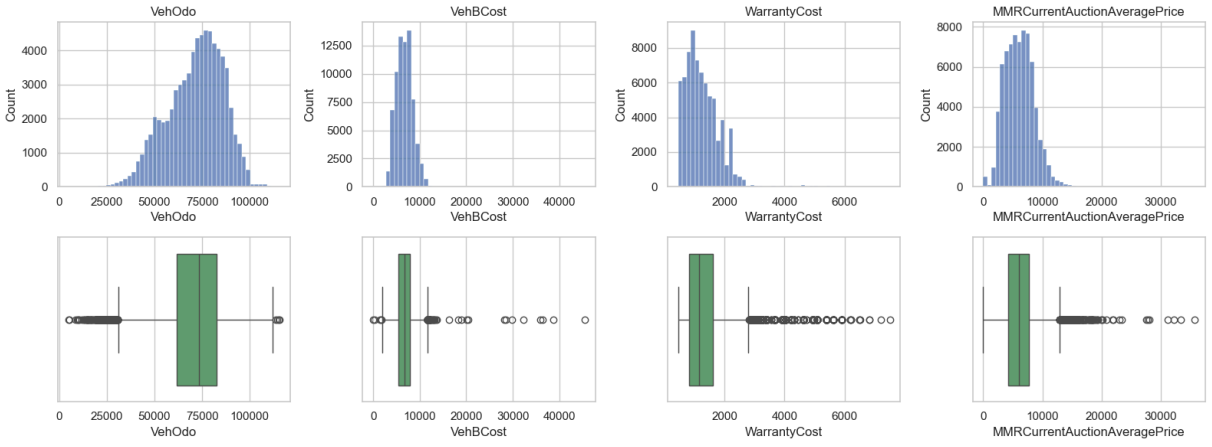


Kết luận: lớp lemon chỉ chiếm **12.3%** (tỉ lệ 1:7.1). Một mô hình luôn đoán 'tốt' đã đạt accuracy **87.7%** nhưng vô dụng -> phải dùng F1/PR-AUC và xử lý imbalance.

2.3 Missing values

Kết luận: có **20/33** cột bị thiếu, tổng **149,271** ô. `PRIMEUNIT` (95.3%) và `AUCGUART` (95.3%) gần như trống -> thiếu có thể mang ý nghĩa (xe không được bảo đảm) nên ta tạo cờ `is_missing` thay vì chỉ điền.

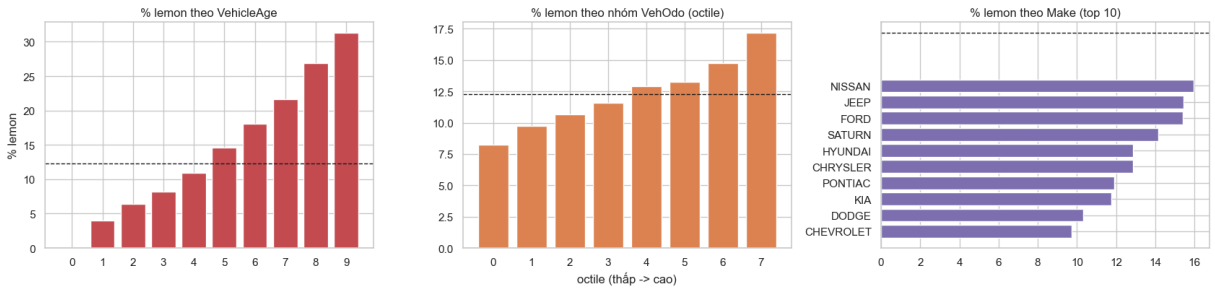
2.4 Numerical: phân phối và outlier



	% outlier theo IQR
VehOdo	0.46
VehBCost	0.24
WarrantyCost	1.15
MMRCurrentAuctionAveragePrice	0.78

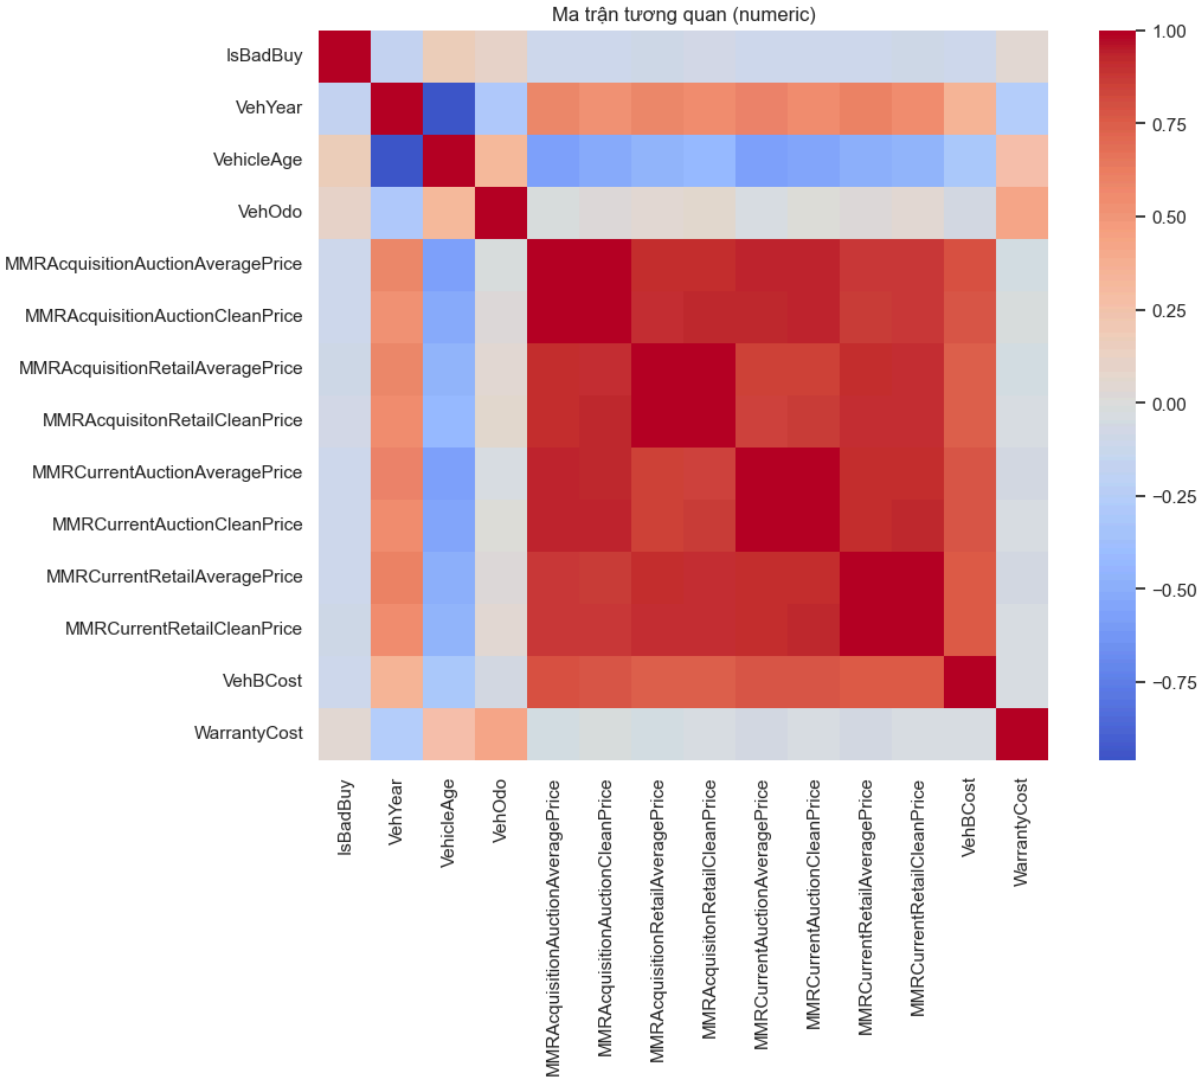
Kết luận: `WarrantyCost` có đuôi phải dài (outlier 1.15%). Nên dùng **RobustScaler** (median/IQR) thay vì StandardScaler để outlier không kéo lệch thang đo.

2.5 Mục tiêu so với các feature (target vs 2–3 feature)



Kết luận: xe càng **già** và chạy càng **nhiều km** thì tỉ lệ lemon càng cao: từ **0.0%** (tuổi 0) lên **31.3%** (tuổi 9); octile km thấp nhất **8.2%** vs cao nhất **17.2%**. Hãng cũng khác biệt (từ 9.7% đến 16.0%). Đường nét đứt = mức trung bình toàn bộ.

2.6 Tương quan giữa các biến số



Kết luận: 8 cột `MMR*` tương quan gần nhau (|r| lên tới **0.99**) -> đa cộng tuyến, ảnh hưởng mô hình tuyến tính. Tương quan tuyến tính với target đều yếu (cao nhất: `VehicleAge` r=0.17) -> cần mô hình phi tuyến.

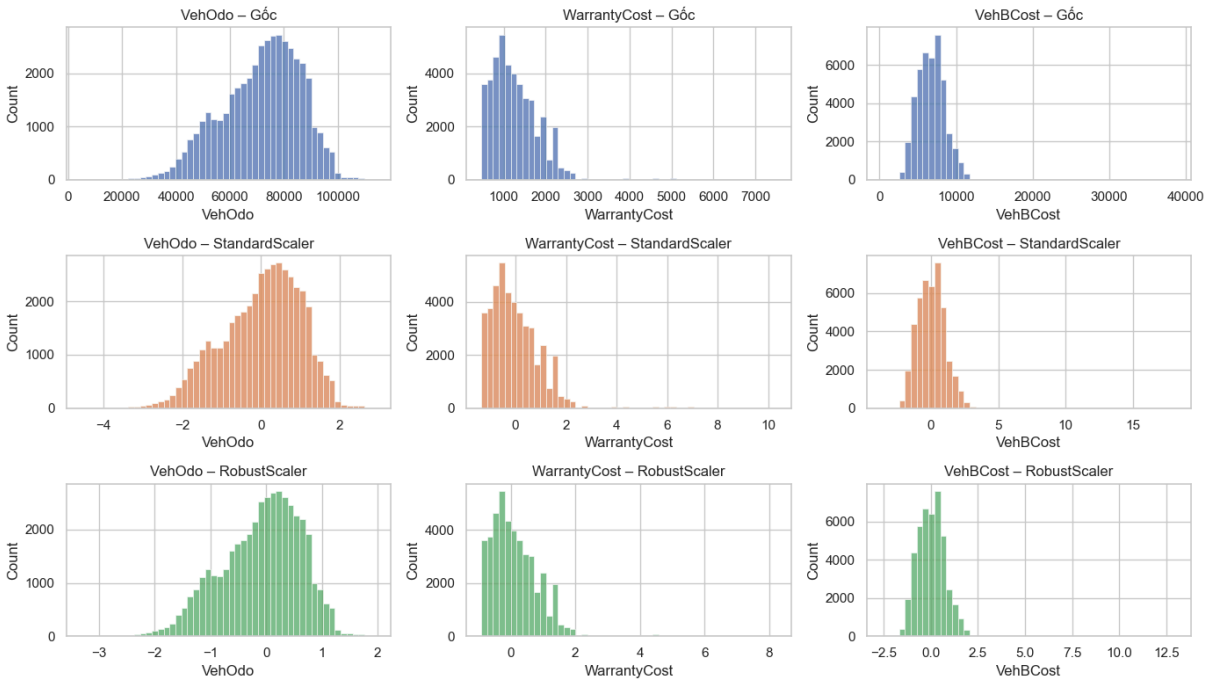
3. Chuẩn bị dữ liệu

1. **Feature engineering:** tách `PurchDate` thành năm/tháng; tạo `age_odo = VehOdo/(VehicleAge+1)`, chênh lệch giá `Acq_vs_Cur = MMRAcquisitionAuctionAveragePrice - MMRCurrentAuctionAveragePrice`, `Cost_vs_MMR = VehBCost / MMRCurrentAuctionAveragePrice`; cờ missing cho `PRIMEUNIT`, `AUCGUART`.
2. **Split 60/20/20 train/val/test, stratify theo target** (split *trước* khi fit bất kỳ bộ biến đổi nào -> tránh data leakage).
3. **Missing:** numeric -> median (fit trên train); categorical -> `"missing"`.
4. **Outlier:** giữ nguyên giá trị nhưng dùng RobustScaler (và cây quyết định vốn bền với outlier).
5. **Encoding:** cardinality ≤ 20 -> One-Hot; cardinality cao (Model, Trim, SubModel, BYRNO, VNZIP1, VNST, Make) -> **Frequency encoding** (fit trên train).
6. **Scaling:** RobustScaler cho numeric.

```
{'train': (43789, np.float64(0.123)), 'val': (14597, np.float64(0.123)), 'test': (1
4597, np.float64(0.123))}

numeric: 20 | low-card cat: ['Auction', 'Color', 'Transmission', 'WheelTypeID', 'Wh
eelType', 'Nationality', 'Size', 'TopThreeAmericanName', 'PRIMEUNIT', 'AUCGUART',
'IsOnlineSale']
high-card cat: ['Make', 'Model', 'Trim', 'SubModel', 'BYRNO', 'VNZIP1', 'VNST']
Số feature sau tiền xử lý: 86
```

3.1 So sánh phân phối trước/sau scaling



Kết luận: với `WarrantyCost`, độ lệch chuẩn = **602** trong khi 'sigma theo IQR' = **571** (tỉ lệ 1.05). Tỉ lệ > 1 nghĩa là outlier làm phồng độ lệch chuẩn nên StandardScaler nén phần lớn dữ liệu vào vùng hẹp hơn; RobustScaler chuẩn hóa theo median/IQR nên không bị outlier chi phối. Cả hai đều giữ nguyên hình dạng phân phối (lệch phải), chỉ đổi thang đo.

4. Mô hình hóa

Huấn luyện 6 cấu hình để so sánh có chủ đích:

#	Mô hình	Mục đích
A	Logistic Regression (baseline)	Mốc tham chiếu
B	Logistic Regression + `class_weight=balanced`	Tác động của xử lý imbalance
C	Random Forest + `class_weight=balanced_subsample`	Mô hình phi tuyến
D	HistGradientBoosting (không xử lý imbalance)	Boosting
E	HistGradientBoosting + `class_weight=balanced`	Boosting + imbalance
F	E + **chỉnh ngưỡng** theo F1 trên validation	Ngưỡng 0.5 không phù hợp lớp hiếm

```
== Validation ==
```

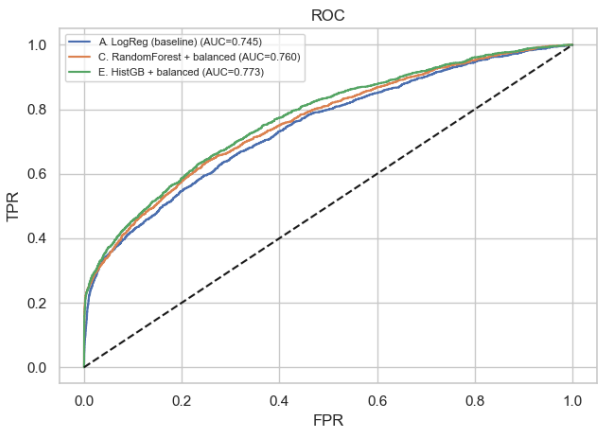
model	thr	accuracy	balanced_acc	precision	recall	F1	ROC_AUC
A. LogReg (baseline)	0.500	0.8955	0.6094	0.7415	0.2301	0.3512	0.7585
B. LogReg + balanced	0.500	0.7460	0.6909	0.2685	0.6178	0.3743	0.7623
C. RandomForest + balanced	0.500	0.8952	0.6354	0.6701	0.2908	0.4056	0.7737
D. HistGB	0.500	0.9025	0.6180	0.8780	0.2407	0.3778	0.7825
E. HistGB + balanced	0.500	0.7766	0.7062	0.3001	0.6128	0.4029	0.7819
F. HistGB + balanced + tuned thr	0.611	0.8585	0.6875	0.4296	0.4607	0.4446	0.7819

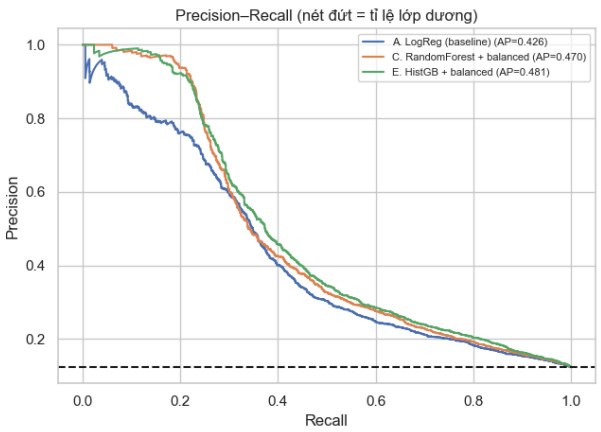
```
== Test ==
```

model	thr	accuracy	balanced_acc	precision	recall	F1	RO
A. LogReg (baseline)	0.500000	0.894700	0.609000	0.727100	0.230100	0.349600	0.
B. LogReg + balanced	0.500000	0.734700	0.678000	0.255100	0.602800	0.358500	0.
C. RandomForest + balanced	0.500000	0.894100	0.632600	0.660200	0.285800	0.398900	0.
D. HistGB	0.500000	0.902000	0.615600	0.879400	0.235700	0.371700	0.
E. HistGB + balanced	0.500000	0.766900	0.694200	0.285900	0.597800	0.386800	0.
F. HistGB + balanced + tuned thr	0.611000	0.852500	0.675200	0.407600	0.440100	0.423300	0.

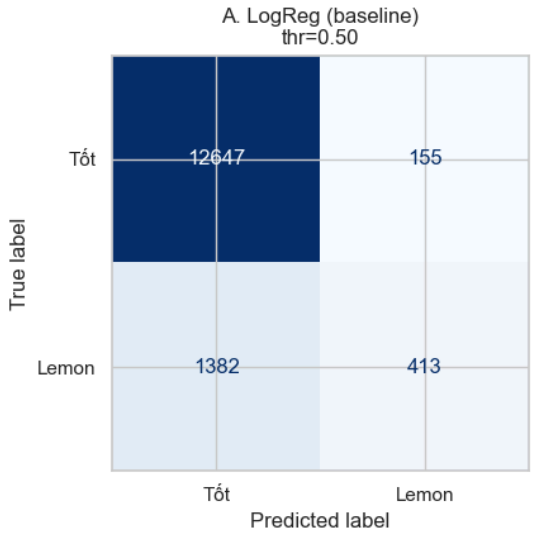
4.1 So sánh mô hình (baseline vs mô hình mở rộng)

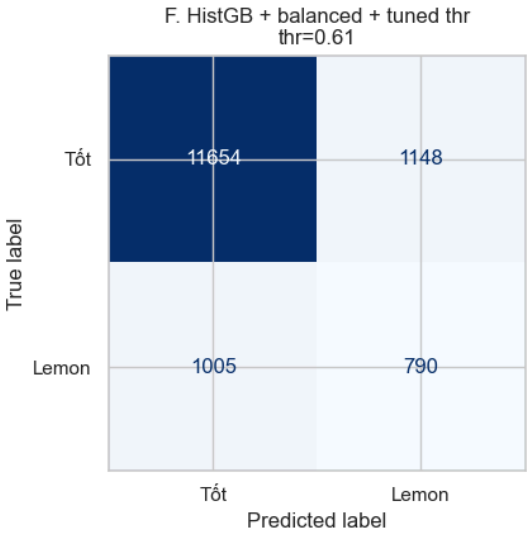
Kết luận: (1) Baseline A có accuracy **0.895** nhưng recall chỉ **0.230** / F1 **0.350** – bị lớp đa số chi phối. (2) `class_weight=balanced` (B) tăng recall lên **0.603** nhưng precision giảm xuống **0.255**. (3) Boosting D đạt PR-AUC **0.493** so với LogReg **0.426**. (4) Chỉnh ngưỡng (F, thr=0.61) cho F1 = **0.423**. Mô hình F1 cao nhất trên test: **F. HistGB + balanced + tuned thr** (F1=0.423).





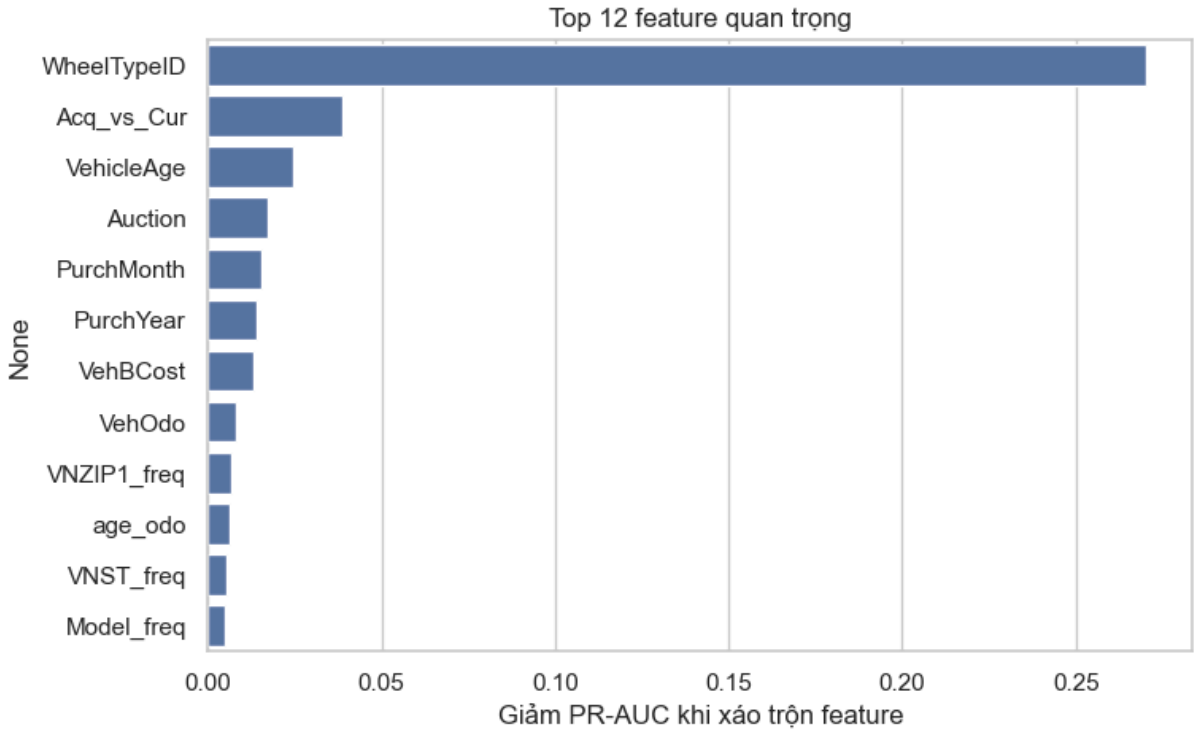
4.2 Confusion matrix: baseline vs mô hình cuối





Kết luận: số lemon bắt được tăng từ **413** (baseline) lên **790** (mô hình cuối) trên tổng **1795** lemon thật; đổi lại số xe tốt bị cảnh báo nhầm tăng từ **155** lên **1148**. Đây là trade-off: chi phí bỏ sót lemon thường cao hơn chi phí kiểm tra thêm xe.

4.3 Feature importance (permutation importance, mô hình E trên test)



Kết luận: 3 feature quan trọng nhất là **WheelTypeID, Acq_vs_Cur, VehicleAge** (giảm PR-AUC 0.270, 0.039, 0.025). Lưu ý `WheelTypeID` (thiếu giá trị ở một nhóm xe) là tín hiệu rất mạnh; cần cẩn trọng vì nếu cách thu thập ID này thay đổi khi triển khai thật thì mô hình sẽ lệch.

5. Tổng kết và mở rộng

Phần này được điền tự động từ bảng metric để kết luận luôn khớp số liệu trong report.

Kết quả chính (tập test, 14,597 mẫu)

Mô hình	F1	Recall	PR-AUC	ROC-AUC
A. LogReg (baseline)	0.350	0.230	0.426	0.745
B. LogReg + balanced	0.358	0.603	0.421	0.747
C. RandomForest + balanced	0.399	0.286	0.470	0.760
D. HistGB	0.372	0.236	0.493	0.775
E. HistGB + balanced	0.387	0.598	0.481	0.773
F. HistGB + balanced + tuned thr	0.423	0.440	0.481	0.773

- **Mô hình tốt nhất theo PR-AUC:** D. HistGB (0.493); theo F1: F. HistGB + balanced + tuned thr (0.423).
- So với baseline: F1 **0.350** → **0.423** (gấp 1.2 lần), recall **0.230** → **0.440**.
- **Accuracy gây hiểu lầm:** baseline accuracy 0.895 cao nhưng F1 thấp, do dữ liệu lệch lớp.

Hạn chế

- ROC-AUC/PR-AUC vẫn ở mức vừa phải -> dữ liệu có nhiễu, thông tin trong bảng không đủ phân biệt hoàn toàn (không có thông tin kiểm định cơ khí).
- Frequency encoding làm mất thông tin về *danh tính* của Model/Trim; chưa tinh chỉnh siêu tham số (chỉ dùng mặc định).
- Chia ngẫu nhiên, chưa kiểm tra drift theo thời gian (`PurchDate`).

Hướng mở rộng

- Target encoding có cross-fitting; tối ưu siêu tham số (RandomizedSearchCV); SMOTE / cost-sensitive threshold theo chi phí kinh doanh thật.
- Chia theo thời gian để kiểm tra mô hình có bền khi triển khai; SHAP để giải thích từng dự đoán.