🌍 Mauna Loa CO_2 Dataset

Báo cáo EDA & Dự báo – Dữ liệu chuỗi thời gian (Time series)

Nền tảng lập trình cho phân tích và trực quan dữ liệu · HK 261, 2026–2027 · GV: Lê Thành Sách

ĐH Bách Khoa – ĐHQG-HCM · Khoa Khoa học và Kỹ thuật Máy tính

Nhóm BugIsFeature · Nguyễn Thị Cẩm Vân · MSSV 2570803

2,284	1958–2001	59
Điểm (tuần)	Khoảng thời gian	Giá trị thiếu

12 tuần	~1.3 ppm/năm
Horizon dự báo	Xu hướng

1. Mô tả bài toán và tập dữ liệu

Môn: Nền tảng lập trình cho phân tích và trực quan dữ liệu – HK 261 (2026–2027) · **GV:** Lê Thành Sách **Nhóm:** BugIsFeature · **Sinh viên:** Nguyễn Thị Cẩm Vân · **MSSV:** 2570803 **Hình thức:** cá nhân · **Loại dữ liệu:** Time series (tự chọn)

- **Nguồn:** `statsmodels.datasets.co2` – đo CO_2 hàng tuần tại Mauna Loa (Scripps), 03/1958 – 12/2001, **2284 điểm**, có **59 giá trị thiếu**.
- **Đặc điểm:** *xu hướng tăng dài hạn + mùa vụ hàng năm* (chu kỳ 52 tuần).
- **Bài toán:** dự báo **12 tuần tới** (horizon h=12) – hồi quy.
- **Nguyên tắc:** chia train/val/test **theo thời gian** (không shuffle), mọi biến đổi chỉ dùng thông tin quá khứ để tránh data leakage.
- **Metric:** MAE, RMSE, MAPE.

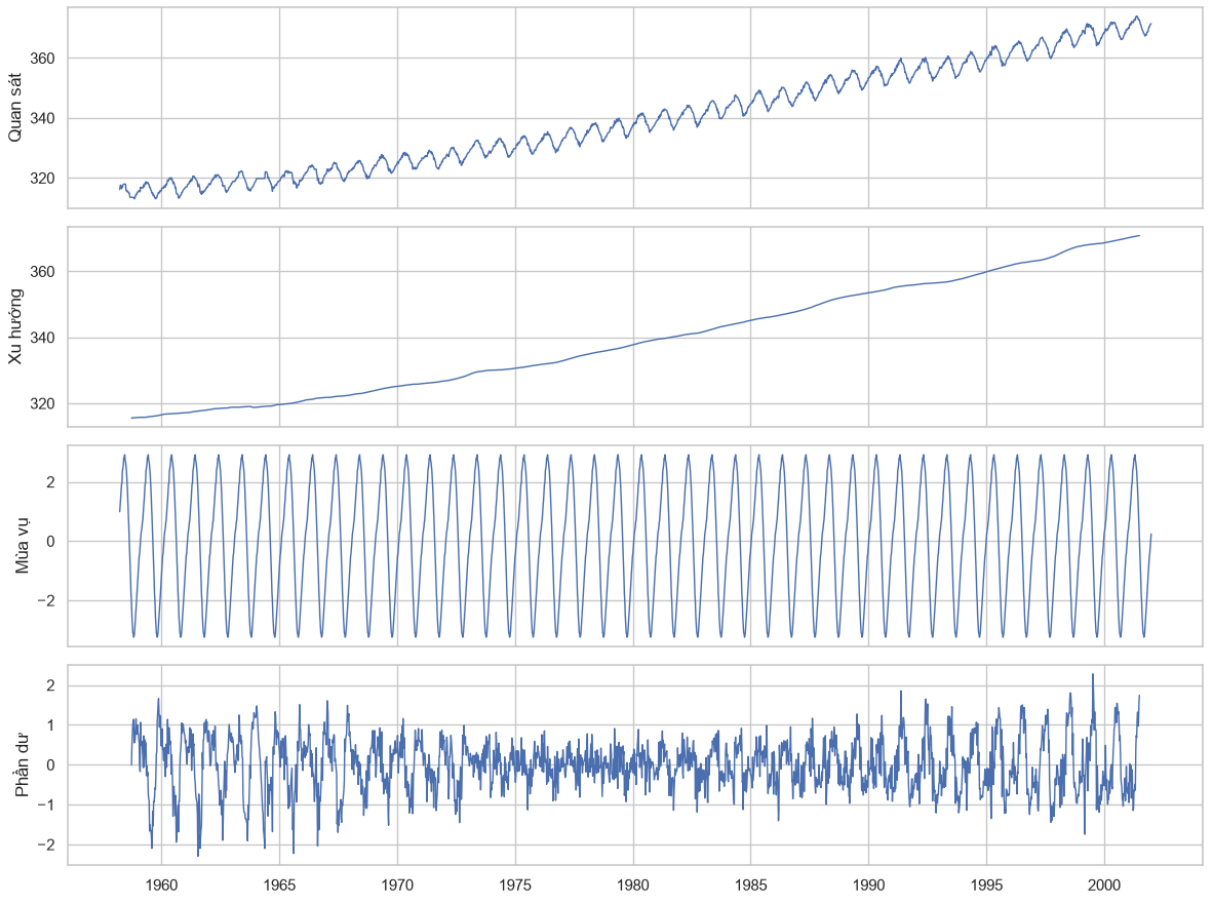
```
(2284,) | thiếu: 59 | tần suất: W-SAT
1958-03-29    316.1
1958-04-05    317.3
1958-04-12    317.6
1958-04-19    317.5
1958-04-26    316.4
Freq: W-SAT, Name: co2, dtype: float64
```

2. Khám phá dữ liệu (EDA)

2.1 Chuỗi gốc và missing

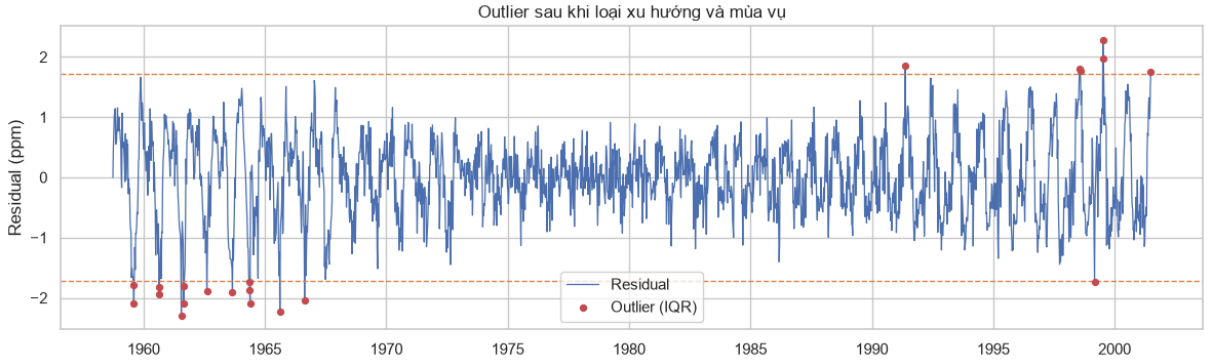
Kết luận: CO_2 tăng từ **316.1** lên **371.5 ppm** (+55.4) trong 44 năm, kèm dao động mùa vụ đều đặn. Có **59** tuần thiếu (2.6%) tạo thành **22** khoảng trống.

2.2 Phân rã xu hướng – mùa vụ – phần dư



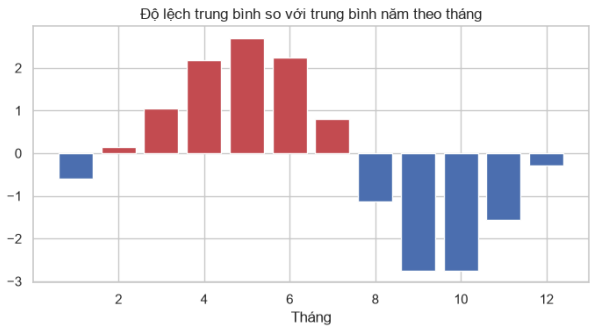
Kết luận: biên độ mùa vụ ≈ **6.2 ppm**, xu hướng tăng ≈ **1.29 ppm/năm**; mùa vụ chỉ giải thích **1.3%** phương sai so với xu hướng. => Mô hình phải *ngoại suy được xu hướng tăng* thì mới dự báo tốt.

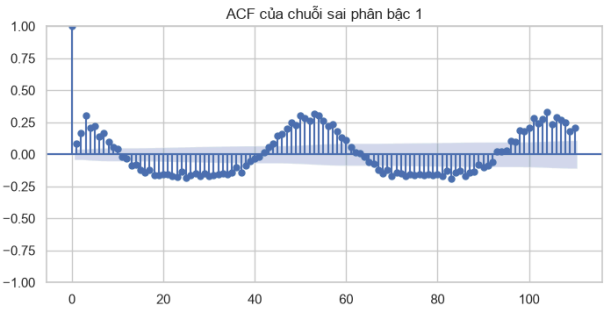
2.3 Phát hiện outlier trên phần dư mùa vụ



Kết luận: phát hiện **21** điểm bất thường (0.94%) ngoài khoảng IQR [-1.72, 1.72] ppm. Không xóa các điểm này vì có thể là biến động khí quyển thật; mô hình cây và metric MAE tương đối bền với outlier. Phần missing vẫn được forward-fill ở bước chuẩn bị dữ liệu.

2.4 Mùa vụ theo tháng và tự tương quan





Kết luận: CO_2 đạt đỉnh vào tháng **5** (+2.70 ppm) và đáy vào tháng **10** (-2.75 ppm) – phù hợp chu kỳ quang hợp của thực vật bán cầu Bắc. ACF có đỉnh quanh lag 52 xác nhận chu kỳ năm -> nên đưa **lag 52** và **sin/cos tuần trong năm** vào feature.

3. Chuẩn bị dữ liệu

1. **Missing:** *forward-fill* (chỉ dùng quá khứ, không rò rỉ tương lai; nội suy tuyến tính sẽ dùng giá trị tương lai).
2. **Feature:** lag 1,2,3,4,8,12,26,52; trung bình trượt 4/12/52 tuần (dịch 0, tính trên quá khứ đến thời điểm t); sin/cos tuần trong năm; chỉ số thời gian `t` (xu hướng).
3. **Target:** giá trị tại **t+12**.
4. **Split theo thời gian:** 70% train / 15% val / 15% test (không shuffle). Với horizon h, hàng cuối cùng của mỗi tập được loại để target không chồng sang tập sau.
5. **Scaling:** StandardScaler fit trên train (cho mô hình tuyến tính).

```
{'train': (1542, '1959-03-21', '1988-10-01'), 'val': (321, '1988-12-31', '1995-02-1
8'), 'test': (334, '1995-05-20', '2001-10-06')}
```

Kết luận: test (1995–2001) nằm hoàn toàn *sau* train, nên đánh giá mô phỏng đúng tình huống dự báo thực tế. Giá trị CO_2 trên test (trung bình 366.1) cao hơn hẳn train (330.8) -> mô hình bị thử thách khi **ngoại suy xu hướng**.

4. Mô hình hóa

Mô hình	Ý tưởng
Naive	dự báo = giá trị hiện tại
Seasonal naive	= giá trị cùng thời điểm năm trước của mốc dự báo (t+12−52)
Ridge (level)	hồi quy tuyến tính dự báo trực tiếp *mức* CO_2
RandomForest (level)	cây quyết định dự báo *mức* – không ngoại suy được
HistGB (level)	tương tự với boosting
RandomForest (delta)	dự báo **mức thay đổi** `y[t+12] - y[t]` rồi cộng lại giá trị hiện tại
HistGB (delta)	tương tự
Ridge (delta)	tương tự

```
alpha Ridge chọn từ validation: 0.1
```

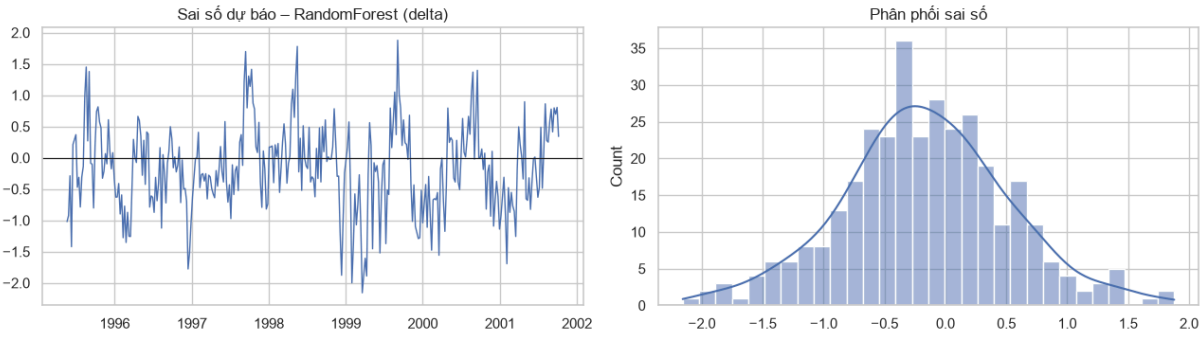
model	MAE	RMSE	MAPE_pct
RandomForest (delta)	0.555000	0.709000	0.151000
HistGB (delta)	0.586000	0.735000	0.160000
Ridge (delta)	0.597000	0.757000	0.163000
Ridge (level)	0.601000	0.759000	0.164000
Seasonal naive + drift	0.651000	0.825000	0.178000
Seasonal naive	1.684000	1.881000	0.460000
Naive	2.769000	3.071000	0.757000
HistGB (level)	15.050000	15.410000	4.099000
RandomForest (level)	16.023000	16.409000	4.363000

4.1 So sánh mô hình: dự báo *level* và *delta*

Kết luận: mô hình tốt nhất là **RandomForest (delta)** (MAE **0.555** ppm, MAPE 0.151%); kém nhất: **RandomForest (level)** (MAE 16.023). Cùng một RandomForest, đổi mục tiêu từ *level* sang *delta* làm MAE giảm **16.023** → **0.555** (giảm 97%) – vì cây không thể dự đoán giá trị lớn hơn mọi giá trị đã thấy trong train, còn dự báo *mức thay đổi* thì không bị giới hạn. So với Naive (MAE 2.769), mô hình tốt nhất giảm sai số 80%.

4.2 Dự báo so với thực tế (tập test)

Kết luận: RandomForest (level) dự báo **thấp hơn thực tế một cách hệ thống** (sai số trung bình +16.02 ppm, nghĩa là luôn thấp hơn), đường dự báo bị 'phẳng' ở mức tối đa đã thấy trong train (354.5 ppm). Mô hình **RandomForest (delta)** bám sát đường thực tế cả xu hướng lẫn mùa vụ (sai số trung bình -0.173 ppm).



Kết luận: sai số khá cân quanh 0 (độ lệch chuẩn 0.689 ppm). Tháng khó dự báo nhất là **tháng 12** (|sai số| TB 0.797), dễ nhất là **tháng 10** (0.406) – thường là các tháng chuyển pha mùa vụ (đỉnh/đáy) nên khó hơn.

4.3 Độ ổn định theo horizon (mở rộng)

Kiểm tra mô hình tốt nhất khi horizon dài hơn (4, 12, 26, 52 tuần) so với Naive.

horizon_weeks	naive_MAE	RF_delta_MAE
4	1.108	0.454
12	2.769	0.557
26	3.733	0.687
52	1.678	0.945

Kết luận: sai số của cả hai tăng theo horizon, nhưng RF (delta) tăng chậm hơn: ở h=52, MAE **0.945** vs Naive **1.678** (giảm 44%). Mô hình tận dụng được mùa vụ nên lợi thế so với Naive lớn dần khi dự báo xa.

5. Tổng kết và mở rộng

Kết quả (test, horizon 12 tuần, 334 mẫu)

Mô hình	MAE	RMSE	MAPE %
RandomForest (delta)	0.555	0.709	0.151
HistGB (delta)	0.586	0.735	0.160
Ridge (delta)	0.597	0.757	0.163
Ridge (level)	0.601	0.759	0.164
Seasonal naive + drift	0.651	0.825	0.178
Seasonal naive	1.684	1.881	0.460
Naive	2.769	3.071	0.757
HistGB (level)	15.050	15.410	4.099
RandomForest (level)	16.023	16.409	4.363

- **Mô hình tốt nhất:** RandomForest (delta) – MAE 0.555 ppm, so với Naive 2.769.
- **Bài học chính:** với chuỗi có xu hướng, mô hình cây dự báo *mức* sẽ thất bại khi ngoại suy (MAE 16.023); dự báo *mức thay đổi* (delta) giải quyết được (MAE 0.555).
- Split theo thời gian + forward-fill bảo đảm không rò rỉ tương lai.

Hạn chế

- Chỉ một chuỗi đơn biến; chưa dùng mô hình thống kê chuyên dụng (SARIMA, ETS, Prophet) để đối chiếu.
- Một lần chia train/val/test; chưa dùng walk-forward CV đầy đủ. Siêu tham số cây để mặc định.
- Dữ liệu dừng ở 2001 – chưa phản ánh giai đoạn tăng tốc sau đó.

Hướng mở rộng

- So sánh với SARIMA/ETS; walk-forward `TimeSeriesSplit`; khoảng tin cậy dự báo (quantile regression).
- Thêm biến ngoại sinh (ENSO, phát thải) và áp dụng cho chuỗi cập nhật mới nhất của NOAA.

Bài tập lớn môn Nền tảng lập trình cho phân tích và trực quan dữ liệu.